LAPORAN UJIAN TENGAH SEMESTER MATA KULIAH BIG DATA Jobsheet 9 – Spark SQL



Dosen Pengampu: M. Hasyim Ratsanjani, S.Kom., M.Kom.

Disusun Oleh:

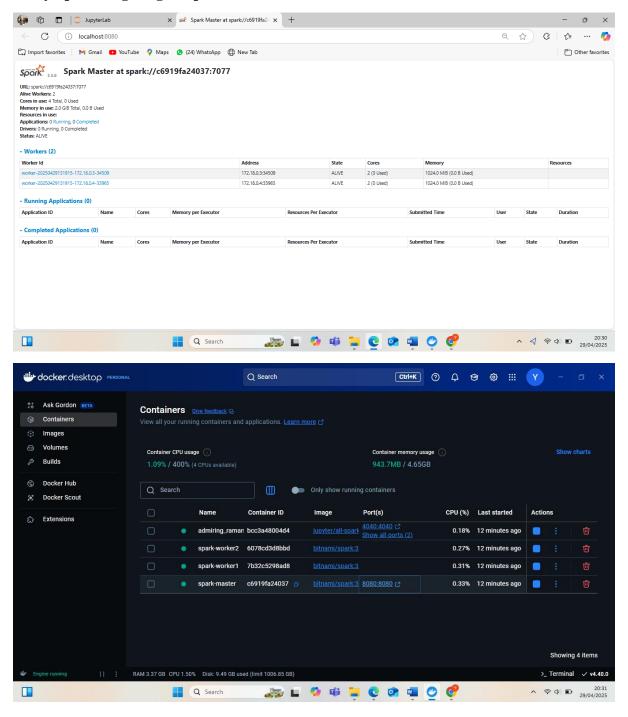
Yuma Rakha Samodra Sikayo

NIM.2241720194

PROGRAM STUDI D4 TEKNIK INFORMATIKA JURUSAN TEKNOLOGI INFORMASI POLITEKNIK NEGERI MALANG 2025

Spark SQL, DataSources, DataFrame, dan Dataset APIs

Menyiapkah lingkungan Spark Cluster



Praktikum: Membangun ETL Pipeline

Tugas

1. Extract: Baca data dari file CSV (sales_data.csv).

2. Transform:

- o Filter transaksi dengan Revenue > \$100.
- o Hitung total penjualan per kategori.
- 3. Load: Simpan hasil ke Parquet.

Solusi

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, sum

spark = SparkSession.builder.appName("ETLPipeline").getOrCreate()

# Extract
df = spark.read.csv("sales_data.csv", header=True, inferSchema=True)

# Transform
df_filtered = df.filter(col("Revenue") > 100)
df_result = df_filtered.groupBy("Product_Category").agg(sum("Revenue").alias("total_sales"))

df_result.show()

# Load
df_result.write.mode("overwrite").parquet("output_sales.parquet")

spark.stop()
```

Hasil

Analisis Data Retail

Dataset

Format: CSV (sales_data.csv)

Tugas

- 1. Hitung total pendapatan per bulan.
- 2. Identifikasi 5 produk terlaris.
- 3. Simpan hasil dalam format Parquet.

Solusi

1. Pendapatan perbulan

```
| month|total_revenue
| 12| 10158080
| 1| 7832338
| 6| 10085537
| 3| 8201790
| 5| 9859851
| 9| 6517880
| 4| 8485163
| 8| 6348349
| 7| 6392045
| 10| 6709394
| 11| 6977157
| 2| 7608734
```

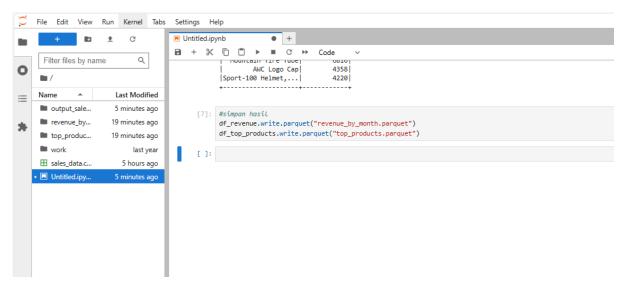
2. Identikasi 5 Produk terlaris

```
from pyspark.sql.functions import count

df_top_products = df.groupBy("Product") \
    .agg(count("*").alias("total_orders")) \
    .orderBy("total_orders", ascending=False) \
    .limit(5)

df_top_products.show()
```

3. Simpan dalam format parquet



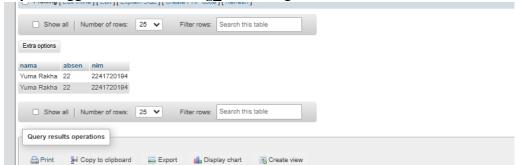
Evaluasi

Soal Latihan

1. Baca data dari table di database MySQL anda menggunakan Spark, dengan cara berikut

Jawab:

a. Saya menggunakan database big data sebagai contoh



b. Melakukan konfigurasi

c. Output

2. Buat query Spark SQL untuk menghitung jumlah row dalam table tersebut